

Guida Concettuale: Trasformare Curve Complesse in Descrittori Armonici

L'efficienza nella modellazione del **Transmission Error (TE)** industriale dipende radicalmente dalla scelta della rappresentazione del segnale. Invece di mappare ogni singolo punto di una curva periodica, l'approccio basato sui descrittori armonici permette di catturare l'essenza della firma meccanica del sistema. Questa guida analizza il passaggio da una visione granulare a una visione strutturata, ottimizzata per l'integrazione in architetture di Machine Learning.

1. Il Cambio di Paradigma: Dal Punto alla Forma

La distinzione tra l'approccio tradizionale e quello armonico risiede nel modo in cui l'informazione viene codificata. Mentre il modello "Direct-TE" deve apprendere la curva punto per punto includendo l'angolo di rotazione tra gli input, l'approccio **Harmonic-wise** (^{RCIM-MBR}) estrae la struttura periodica globale, rendendo il processo di regressione significativamente più efficiente per segnali ciclici.

Caratteristica	Approccio Punto per Punto (Direct-TE)	Approccio Armonico (Harmonic-wise)
Obiettivo di Previsione	Il valore puntuale della curva per ogni specifico angolo.	L'essenza matematica e la struttura della curva completa.
Input del Modello	Condizioni operative + Angolo di rotazione (θ).	Solo Condizioni operative (velocità, coppia, temperatura, direzione).
Efficienza	Elevato costo computazionale per mappare ogni posizione.	Estremamente compatto: pochi descrittori definiscono l'intera forma.
Filosofia di Apprendimento	Accuratezza locale sul singolo campione di segnale.	Ricostruzione globale del comportamento periodico del sistema.

Il concetto di "riassunto di una curva" rappresenta la chiave di volta per l'efficienza del sistema.

2. L'Anatomia del Segnale: La Scomposizione (Decomposition)

Per trasformare una curva TE in un formato compatibile con gli algoritmi di apprendimento supervisionato, è necessaria una scomposizione in armoniche selezionate. Queste frequenze non sono arbitrarie, ma rappresentano la struttura periodica critica del sistema meccanico identificata nel protocollo di benchmark. Le armoniche specifiche utilizzate in questa pipeline sono:

- **0, 1, 3** (Componenti fondamentali e a bassa frequenza)
- **39, 40, 78, 81** (Medie frequenze e interazioni meccaniche)
- **156, 162, 240** (Alte frequenze e armoniche superiori)

La Formula della Scomposizione Il segnale viene parametrizzato come una serie troncata di onde fondamentali:

$$TE(\theta) \approx a_0 + \sum c_k \cos(k\theta) + \sum s_k \sin(k\theta)$$

Dove a_0 è il termine di offset e i coefficienti c_k e s_k (seno e coseno) definiscono il contributo di ogni armonica k . Questi parametri astratti diventano i nuovi target per il nostro modello di intelligenza artificiale.

3. Il Linguaggio dei Descrittori: Coefficienti, Ampiezza e Fase

Nella costruzione della pipeline, la scelta della **parameterization** è fondamentale per garantire la **regression stability**. Sebbene l'intuizione fisica ci porti a pensare in termini di

ampiezza e fase, il modello matematico lavora con i coefficienti cartesiani per evitare le discontinuità tipiche della fase.

1. **Coefficienti (c_k, s_k)**: Rappresentano le coordinate dell'onda nel dominio armonico. L'uso di coppie di coefficienti assicura che il modello possa apprendere in modo stabile senza gestire i salti della funzione arcotangente.
2. **Ampiezza (A_k)**: Definita come $A_k = \sqrt{c_k^2 + s_k^2}$, indica l'intensità fisica della vibrazione o dell'errore per quella specifica armonica.
3. **Fase (ϕ_k)**: Calcolata come $\text{atan2}(-s_k, c_k)$, definisce il posizionamento angolare dell'onda, ovvero dove "inizia" il contributo periodico all'interno del ciclo. Ora che abbiamo i descrittori, dobbiamo capire come cambia il modo in cui insegniamo alla macchina a riconoscerli.

4. La Trasformazione del Dataset: Un Nuovo Modo di Imparare

Il passaggio alla modellazione armonica comporta un **Conceptual Shift** radicale: l'angolo θ scompare dagli input del modello. Il problema non è più prevedere "cosa succede a questo angolo", ma "quale firma armonica viene generata da queste condizioni operative". **Schema dell'Architettura di Apprendimento:**

[Input: Condizioni Operative]	[Modello Regressore]	
[Output: Descrittori Armonici]		
- Velocità (Speed)	-> [HistGradientBoosting]	->
- Offset (a_0)		
- Coppia (Torque)	-> Stack	->
- Coefficienti Cos (c_k)		
- Temperatura	-> Multi-target	->
- Coefficienti Sin (s_k)		
- Direzione (Dir)		

In questo assetto, ogni campione supervisionato associa un punto operativo a un intero "pacchetto" di armoniche che descrive la forma completa della curva. Una volta che il modello ha predetto questi descrittori compatti, il passo finale è tornare al mondo fisico.

5. Dalla Teoria alla Realtà: Ricostruzione e Valutazione

La **TE Reconstruction** agisce come ponte tra i coefficienti predetti e il comportamento fisico osservabile. Ricostruendo la curva completa dai descrittori, possiamo validare il modello rispetto ai dati reali utilizzando metriche come il **Mean Percentage Error**. Un elemento cruciale di questa metodologia è l'uso del **"truncation-only oracle"**. I test dimostrano che una scomposizione basata esclusivamente sulle 10 armoniche selezionate (senza l'errore del modello ML) raggiunge una precisione estremamente elevata. Ciò prova che il set armonico è sufficientemente espressivo e che l'attuale collo di bottiglia risiede esclusivamente nel regressore. **Analisi del Benchmark Offline** ^(RCIM-MBR)

- **Errore attuale nei test:** 9.403%
- **Target A (Obiettivo Paper):** $\leq 4.7\%$ Sebbene il sistema debba essere ulteriormente affinato per raggiungere il Target A, l'architettura è solida: l'errore è limitato alla capacità predittiva delle condizioni operative, non alla perdita di informazione nella scomposizione armonica. Questo percorso è intrinsecamente più interpretabile e strutturato rispetto a un modello di tipo "black box".

6. Orizzonti Futuri e Conclusioni

L'approccio armonico non è solo un esercizio matematico, ma un protocollo di benchmark offline fondamentale (^{RCIM-MBR}) che prepara il terreno per la compensazione online in tempo reale. Stabilizzare la previsione della "firma" del segnale è il prerequisito essenziale per ogni sistema di controllo industriale di precisione. **Key Takeaways:**

1. **Compattezza:** La riduzione di una curva complessa a pochi coefficienti armonici riduce drasticamente la dimensionalità del problema di apprendimento.
2. **Interpretabilità:** La scomposizione permette di isolare quali frequenze meccaniche sono più influenzate da variabili come coppia o temperatura, facilitando il debugging industriale.
3. **Ricostruzione Fisica:** Il successo del modello viene misurato sulla capacità di ricostruire il segnale nel dominio angolare, garantendo la fedeltà al comportamento meccanico reale.